

Metody Obliczeniowe w Nauce i Technice

Laboratorium 5 — Aproksymacja

Mateusz Stoch

14 kwietnia 2026

1 Zadanie 1 — Aproksymacja populacji USA

1.1 Opis zadania

Dane wejściowe to populacja Stanów Zjednoczonych w latach 1900–1980 (9 punktów co 10 lat). Należy:

- (a) Wykonać aproksymację średniokwadratową wielomianami stopnia $m = 0, 1, \dots, 6$ i ekstrapolować każdy wielomian do roku 1990. Porównać wyniki z prawdziwą wartością 248 709 873 i znaleźć stopień m dający najmniejszy błąd względny.
- (b) Wyznaczyć optymalny stopień m za pomocą kryterium informacyjnego Akaikiego ze składnikiem korygującym (AICc) i sprawdzić, czy pokrywa się on z wynikiem z punktu (a).

1.2 Argumentacja rozwiązania

1.2.1 Normalizacja argumentu

Dane obejmują lata 1900–1990. Używanie surowych lat jako argumentów wielomianu prowadziłyby do ogromnych wartości liczbowych i złego uwarunkowania macierzy układu. Dlatego argumenty normalizuje się do przedziału $[-1, 1]$:

$$t = \frac{\text{rok} - 1940}{40}.$$

Rok 1990 odpowiada $t_{1990} = (1990 - 1940)/40 = 1,25$.

1.2.2 Aproksymacja średniokwadratowa

Aproksymacja różni się od interpolacji, ponieważ nie wymaga, by wielomian dokładnie przechodził przez węzły. Szukamy wielomianu $\hat{y}(t)$, który *minimalizuje* sumę kwadratów odchyleń:

$$\min_{\mathbf{c}} \sum_{i=1}^n [y_i - \hat{y}(t_i)]^2.$$

W praktyce sprowadza się to do rozwiązania układu *normalnych równań* lub rozwiązania zadania metodą najmniejszych kwadratów (np. `np.linalg.lstsq`).

```

1 def fit_polynomial_ls(t_data, y_data, m):
2     A = np.vander(t_data, N=m + 1, increasing=True)
3     c, residuals, rank, sv = np.linalg.lstsq(A, y_data, rcond=None)
4     return c

```

Listing 1: Dopasowanie wielomianu stopnia m metodą najmniejszych kwadratów

1.2.3 Kryterium AICc


Kryterium informacyjne Akaikego pozwala wybrać kompromis między dokładnością modelu a jego złożonością. Dla próbki o małym rozmiarze ($n/k < 40$, gdzie $k = m + 1$) stosuje się wersję skorygowaną:

$$AIC = 2k + n \ln\left(\frac{SSE}{n}\right), \quad AICc = AIC + \frac{2k(k+1)}{n-k-1},$$

gdzie $SSE = \sum_{i=1}^n [y_i - \hat{y}(t_i)]^2$. Mniejsza wartość AICc odpowiada lepszemu modelowi.

1.3 Wykresy i wyniki

1.3.1 (a) Ekstrapolacja do 1990



Wykres 1: Wielomiany aproksymujące populację USA (stopnie $m = 0 \dots 6$) z ekstrapolacją do roku 1990. Punkty danych: 1900–1980.


Tabela 1: Ekstrapolacja do roku 1990 – porównanie wyników.

m	Predykcja 1990	Błąd względny [%]
0	143 369 177	$\approx 42,35\%$
1	235 808 109	$\approx 5,19\%$
2	254 712 945	$\approx 2,41\%$
3	261 439 380	$\approx 5,12\%$
4	243 106 971	$\approx 2,25\%$
5	220 442 802	$\approx 11,37\%$
6	255 044 185	$\approx 2,55\%$

Prawdziwa populacja w 1990: 248 709 873.

Najmniejszy błąd względny dla $m = 4$: $\approx 2,25\%$.

1.3.2 (b) Kryterium AICc



Wykres 2: Wartości AICc dla wielomianów stopnia $m = 0 \dots 6$.

Tabela 2: Zestawienie wartości SSE, AIC i AICc dla każdego stopnia.

m	$k=m+1$	n/k	SSE	AIC	AICc
0	1	9,00	$2,09 \times 10^{16}$	320,44	321,01
1	2	4,50	$4,10 \times 10^{14}$	287,06	289,06
2	3	3,00	$8,28 \times 10^{13}$	274,65	279,45
3	4	2,25	$6,80 \times 10^{13}$	274,88	284,88
4	5	1,80	$3,51 \times 10^{13}$	270,93	290,93
5	6	1,50	$2,33 \times 10^{13}$	269,26	311,26
6	7	1,29	$1,87 \times 10^{13}$	269,27	381,27

Najmniejsze AICc dla $m = 2$ (AICc = 279,45).

Najlepszy błąd ekstrapolacji: $m = 4$, wyniki się **nie** pokrywają.

1.4 Wnioski

1. Wielomian stopnia 0 (stała) dał błąd ponad 42%, ponieważ nie jest w stanie opisać żadnego trendu.
2. Wielomian liniowy ($m = 1$) znacznie lepiej opisuje dane (błąd $\approx 5\%$), ale nadal zbyt prosto odwzorowuje krzywoliniowy trend populacji.
3. Najlepszą predykcję dla roku 1990 dał wielomian stopnia 4 ($\approx 2,25\%$ błędu). Jednocześnie AICc wybiera $m = 2$ jako kompromis między jakością dopasowania a ryzykiem przeuczenia. Rozbieżność wynika z tego, że AICc “karze” modele wieloparametrowe przy małych zbiorach danych, czyli gdy $n = 9$ i k rośnie, n/k gwałtownie maleje, a składnik karny rośnie.
4. Modele o wyższych stopniach ($m = 5, 6$) dobrze dopasowują dane treningowe (SSE maleje), ale gorzej ekstrapolują (błąd rośnie), co jest klasycznym objawem przeuczenia.
5. AICc stara się ten problem wykryć *bez* zestawu testowego, za pomocą kryterium opartego na danych treningowych. W tym zadaniu sprawdza się, ponieważ chroni przed wyborem zbyt złożonego modelu.

2 Zadanie 2 — Aproksymacja $\sqrt{x}$ wielomianami Czebyszewa

2.1 Opis zadania

Należy wykonać aproksymację ciągłą funkcji $f(x) = \sqrt{x}$ na przedziale $[0, 2]$ wielomianem drugiego stopnia, korzystając z wielomianów Czebyszewa jako bazy. Cel jest znalezienie wielomianu

$$p_2(x) = c_0 T_0(x') + c_1 T_1(x') + c_2 T_2(x'),$$

gdzie $x' = x - 1$ przelicza $[0, 2]$ na $[-1, 1]$, a T_k to k -ty wielomian Czebyszewa.

2.2 Argumentacja rozwiązania

2.2.1 Wielomiany Czebyszewa

Wielomiany Czebyszewa $T_k(\xi)$ są zdefiniowane rekurencyjnie:

$$T_0(\xi) = 1, \quad T_1(\xi) = \xi, \quad T_{k+1}(\xi) = 2\xi T_k(\xi) - T_{k-1}(\xi).$$

Tworzą one bazę ortogonalną na $[-1, 1]$ z wagą $w(\xi) = 1/\sqrt{1 - \xi^2}$:

$$\int_{-1}^1 T_i(\xi) T_j(\xi) \frac{d\xi}{\sqrt{1 - \xi^2}} = \begin{cases} 0 & i \neq j \\ \pi/2 & i = j \neq 0 \\ \pi & i = j = 0. \end{cases}$$

2.2.2 Wyznaczanie współczynników

Z ortogonalności wynika wzór na współczynniki:

$$c_k = \frac{2}{\pi} \int_{-1}^1 f(x') T_k(\xi) \frac{d\xi}{\sqrt{1-\xi^2}}, \quad k > 0,$$

(dla c_0 czynnik $2/\pi$ zastępuje się $1/\pi$). Całkę oblicza się numerycznie kwadraturą Gaussa–Czebyszewa:

$$\int_{-1}^1 g(\xi) \frac{d\xi}{\sqrt{1-\xi^2}} \approx \frac{\pi}{N} \sum_{j=1}^N g\left(\cos \frac{(2j-1)\pi}{2N}\right).$$

Poniżej kluczowe fragmenty implementacji:

```
1 def chebyshev_T(k, t):
2     if k == 0:
3         return np.ones_like(t, dtype=float)
4     elif k == 1:
5         return np.asarray(t, dtype=float).copy()
6     else:
7         T_prev2 = np.ones_like(t, dtype=float)
8         T_prev1 = np.asarray(t, dtype=float).copy()
9         for _ in range(2, k + 1):
10             T_curr = 2 * t * T_prev1 - T_prev2
11             T_prev2 = T_prev1
12             T_prev1 = T_curr
13     return T_curr
```

Listing 2: Rekurencyjne obliczanie wielomianów Czebyszewa

```
1 N_quad = 500
2 j_idx = np.arange(1, N_quad + 1)
3 theta_j = (2 * j_idx - 1) * np.pi / (2 * N_quad)
4 t_j = np.cos(theta_j)          # wezly Gaussa-Czebyszewa
5 x_j = t_j + 1                  # przedzial [0, 2]
6 f_j = np.sqrt(x_j)
7
8 deg = 2
9 c = np.zeros(deg + 1)
10 c[0] = np.sum(f_j) / N_quad
11 for k in range(1, deg + 1):
12     c[k] = 2.0 / N_quad * np.sum(f_j * np.cos(k * theta_j))
```

Listing 3: Wyznaczanie współczynników aproksymacji Czebyszewa


2.3 Wyniki

Wyznaczone współczynniki (w bazie Czebyszewa, na $[-1, 1]$):

$$c_0 \approx 0,9003, \quad c_1 \approx 0,6002, \quad c_2 \approx -0,1200.$$

Wielomian w postaci standardowej:

$$p(x) \approx 0,1801 + 1,0804 \cdot x - 0,2401 \cdot x^2.$$




Wykres 3: Aproxymacja $f(x) = \sqrt{x}$ wielomianem 2. stopnia (baza Czebyszewa) i wykres błędu bezwzględnego.

Błędy aproksymacji:

- Maksymalny błąd bezwzględny: $\|f - p\|_{\infty} \approx 1,80 \times 10^{-1}$
- Błąd $L_2 \approx 5,21 \times 10^{-2}$

2.3.1 Porównanie z klasyczną metodą MNK



Wykres 4: Porównanie aproksymacji Czebyszewa z klasycznym wielomianem MNK stopnia 2 oraz wykresy błędów obu metod.

2.4 Wnioski

1. Baza Czebyszewa daje *aproksymację średniokwadratową*, ponieważ minimalizuje maksymalne odchylenie od funkcji globalnie na całym przedziale.

2. Standardowa aproksymacja MNK minimalizuje sumę kwadratów odchyleń (norma L_2), co może prowadzić do większych błędów w skrajnych punktach przedziału w porównaniu z metodą Czebyszewa.
3. Metoda Czebyszewa jest dobrze uwarunkowana ze względu na ortogonalność bazy, a współczynniki wyznacza się niezależnie, bez rozwiązywania układu równań.
4. Aproksymacja wielomianami Czebyszewa jest *tania obliczeniowo*, ponieważ zamiast rozwiązywać układ $m \times m$, obliczamy m niezależnych całek.
5. Dla $m = 2$ błąd $L_2 \approx 5,21 \times 10^{-2}$, co jest dobrym wynikiem dla wielomianu tak niskiego stopnia na przedziale $[0, 2]$.

3 Podsumowanie

1. **Aproksymacja a interpolacja.** Aproksymacja nie musi przechodzić przez węzły, dzięki czemu jest odporna na szum w danych i unika problemów z przeuczeniem.
2. **Wybór stopnia wielomianu.** Zbyt niski stopień (underfitting) oznacza, że model nie opisuje trendu. Zbyt wysoki (overfitting) oznacza, że model uczy się szumu i źle generalizuje. Kryterium AICc pozwala automatycznie wybrać kompromis bez potrzeby posiadania zestawu testowego.
3. **Baza Czebyszewa** jest lepszym wyborem niż baza potęgowa dla aproksymacji ciągłej, ponieważ jest stabilna numerycznie, daje aproksymację quasi-jednostajną i może zastąpić kosztowną aproksymację minimax.
4. **Normalizacja dziedziny** (np. liniowe przekształcenie do $[-1, 1]$) jest niezbędna, by uniknąć złego uwarunkowania macierzy przy użyciu bazy potęgowej lub Czebyszewa.